Universidade Estadual de Campinas

Faculdade de Engenharia Elétrica e de Computação

IA048 – Aprendizado de Máquina 15 de abril de 2024

Docentes: Levy Boccato & Romis Attux

Discente:

– Gabriel Toffanetto França da Rocha – 289320

Atividade 2 – Classificação

Sumário

1 Apresentação dos dados

O problema de classificação com o reconhecimento de atividades humanas utiliza como base de dados amostras tomadas do acelerômetro e do giroscópio do *smartphone* preso à cintura do candidato. Dessa forma, com base na leitura desses sensores, pode-se identificar se a pessoa está caminhando, subindo escadas, descendo escadas, sentada, de pé ou deitada, que representam as seis classes do problema.

Os dados brutos utilizados são formados da concatenação das 128 medições dos sensores de orientação e aceleração, para os eixos x, y e z, em cada janela de tempo. Dessa forma, chega-se a um *dataset* de treinamento e teste com 768 atributos. São um total de 7352 amostras para treinamento e validação, e 2947 amostras para teste.

Além dos dados brutos, é fornecido também os dados processados, com extração sobre os dados no tempo, na frequência, e também características estatísticas dos mesmos. Os dados tratados são formados por amostras de 561 atributos derivados da análise no tempo e na frequência dos dados provenientes do acelerômetro e do giroscópio do *smartphone*.

O balanceamento das classes nos conjuntos de dados foi realizado por meio do cálculo da taxa de ocorrência dos mesmos, dada de acordo com (1). A Figura 1 mostra a distribuição das classes, e pode-se ver que não existe um balanceamento homogêneo, onde a classe 3 é a que menos ocorre, enquanto a classe 6 é a que mais ocorre.

Devido a esse desbalanceamento, a métrica que será utilizada para a avaliação do desempenho de cada classificador será a acurácia balanceada, dada por (2).

$$Rate_i = \frac{N_i}{N} \tag{1}$$

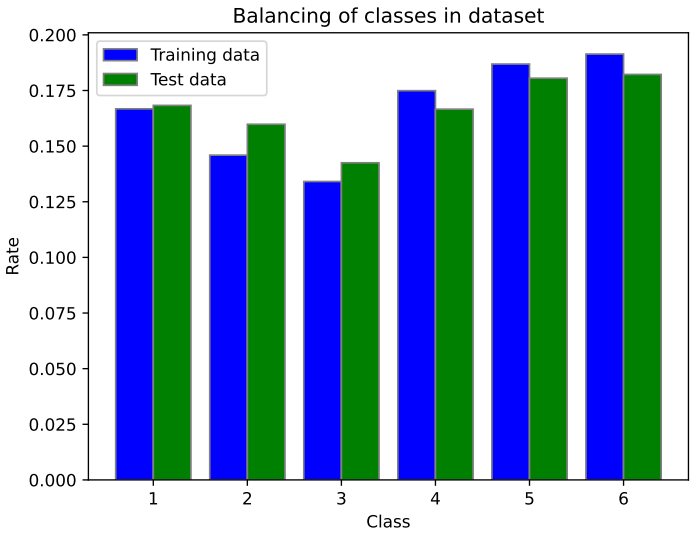

Figura 1: Gráfico da ocorrência das classes nos conjuntos de dados de treinamento e teste.

$$BA = \frac{\sum_{i=1}^{Q} Recall_i}{Q} = \frac{\sum_{i=1}^{Q} \frac{\mathrm{TP}_i}{N_i}}{Q} = \frac{\sum_{i=1}^{Q} \frac{\mathrm{TP}_i}{N \cdot Rate_i}}{Q} \tag{2}$$

2 Classificação via Regressão Logística

A classificação multi-classe é feita de forma elegante ao ter um modelo, que dadas Q classes à serem reconhecidas, apresente Q saídas, onde cada saída é a probabilidade da amostra pertencer à classe em questão. Tal implementação se dá por meio da função *softmax*, enunciada em (3), e a saída é dada pela notação *one-hot encoding*.

$$\hat{y}_k(\mathbf{x}(i)) = \frac{e^{\left(\mathbf{\Phi}(\mathbf{x}(i))^T \mathbf{w}_k\right)}}{\sum_j e^{(\mathbf{\Phi}(\mathbf{x}(i))^T \mathbf{w}_j)}} \tag{3}$$

Onde o $\mathbf{w}_k$ é o vetor de pesos para a classe k, e a matriz de pesos $\mathbf{W}$ é dada por (4).

$$\mathbf{W} = \begin{bmatrix} \mathbf{w}_1 \\ \mathbf{w}_2 \\ \vdots \\ \mathbf{w}_Q \end{bmatrix} \tag{4}$$

Não existe forma fechada para a obtenção dos pesos de $\mathbf{W}$, logo, o mesmo precisa ser feito de forma iterativa. A métrica utilizada como função de custo para o problema é a entropia cruzada, dada por (5). O otimização dos pesos se dá pela técnica do gradiente descendente, dado por (6).

$$J_{CE}(\mathbf{W}) = -\sum_{i=0}^{N-1} \sum_{k=1}^{Q} y_{i,k} \log\left[\hat{y}_k(\mathbf{x}(i)\right] \tag{5}$$

$$\frac{\partial J_{CE}(\mathbf{W})}{\partial \mathbf{w}_k} = \sum_{i=0}^{N-1} \left(y_{i,k} - \hat{y}_k\left(\mathbf{x}(i)\right)\right) \mathbf{\Phi}(\mathbf{x}(i))^T \tag{6}$$

A atualização dos pesos é dada por (7), onde l é a iteração dos pesos.

$$\mathbf{W}[l+1] = \mathbf{W}[l] - \eta \nabla \mathbf{W} \tag{7}$$

Devido ao tamanho do conjunto de dados, foi proposto o treinamento por *mini-batch*, testadas com tamanhos de 500, 1000 e 2000 amostras, e um passo (η) de 0,01, que apresentou boa convergência nos testes realizados *a priori*. O processo de validação cruzada para o treinamento do modelo foi feito na forma *holdout*, considerando o conjunto de validação 30% do *dataset* de treinamento. A inicialização dos pesos foi feita de forma aleatória, seguindo uma distribuição gaussiana, nos entornos de 0.

2.1 Dados tratados

Mini-batch 500 amostras

Para um primeiro caso, treinou-se o modelo de regressão logística utilizando o *mini-batch* de 500 amostras. A cada 500 amostras de treinamento, entregues em ordem aleatória a cada época, realiza-se a evolução da matriz de pesos $\mathbf{W}$, calculando a nova função de custo (entropia cruzada), e o valor da acurácia balanceada, para todo conjunto de treinamento e validação.

A Figura 2a mostra o decaimento da entropia cruzada de treinamento e validação durante as épocas de treinamento. Para 500 épocas, observa-se que não há o estado de regime das métricas, ou a inversão do crescimento da entropia cruzada de validação, que indicaria *overfitting*. Porém, analisando a acurácia balanceada do modelo, exibida na Figura 2b, percebe-se que a medida de desempenho apresenta saturação, após aproximadamente 300 épocas de treinamento, sendo assim utilizada para a parada antecipada (*early stopping*) do treinamento do modelo.

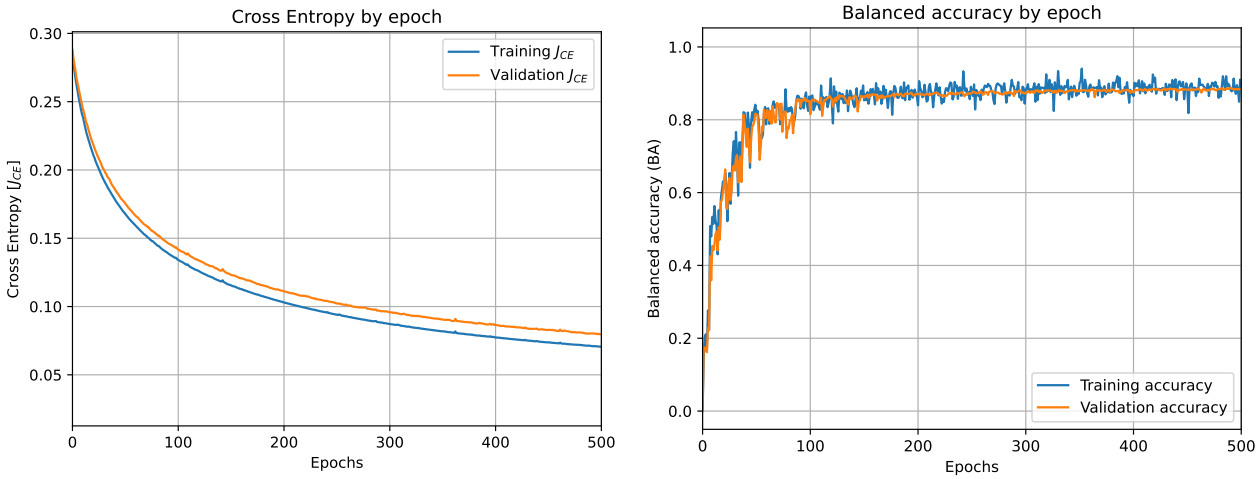

(a) Evolução da entropia cruzada.

(b) Evolução da acurácia balanceada.

Figura 2: Evolução da entropia cruzada e da acurácia balanceada durante o treinamento para *mini-batch* de 500 amostras e $\eta = 0,01$.

Com o treinamento, obteve-se um classificador que ao aplicar os dados de teste, obteve uma acurácia balanceada média de 0,9162, com matriz de confusão mostrada na Tabela 1 e métricas de precisão e *recall* por classe listadas na Tabela 2. Observa-se facilmente o grande desempenho do classificador para a classe 6, possuindo total assertividade em identificar a classe, sem haver nenhum engano da classe com as outras, e vice-versa. Pela matriz, observa-se grande confusão da classe 1 com a classe 2 e 3, justificando a mesma possuir o menor *recall*. Já a classe 3 é a que possuí menor precisão, sendo classificada erroneamente como a classe 1 e 2.

$$BA = 0,9162 \tag{8}$$

	1	**2**	**3**	**4**	**5**	**6**
1	486	0	10	0	0	0
2	30	440	1	0	0	0
3	39	52	329	0	0	0
4	0	3	0	424	64	0
5	1	0	0	33	498	0
6	0	0	0	0	0	537

Tabela 1: Matriz de confusão do classificador com *mini-batch* de 500 amostras.

Classe	**Precisão**	***Recall***
1	0.9798	0.8741
2	0.9342	0.8889
3	0.7833	0.9676
4	0.8635	0.9278
5	0.9361	0.8861
6	1.0000	1.0000

Tabela 2: Precisão e *Recall* por classe do classificador com *mini-batch* de 500 amostras por classe.

Mini-batch 1000 amostras

Ao aumentar o tamanho de amostras por atualização da matriz de pesos, observa-se uma convergência mais suave e mais assertiva, apresentando uma curva de acurácia balanceada (Figura 3b) mais bem comportada, devido à apresentar uma maior média de amostras para formar uma iteração de $\mathbf{W}$ pelo gradiente negativo da entropia cruzada (Figura 3a).

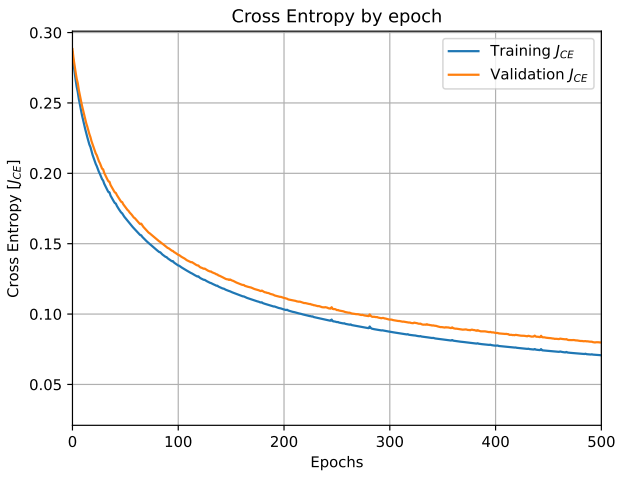

(a) Evolução da entropia cruzada.

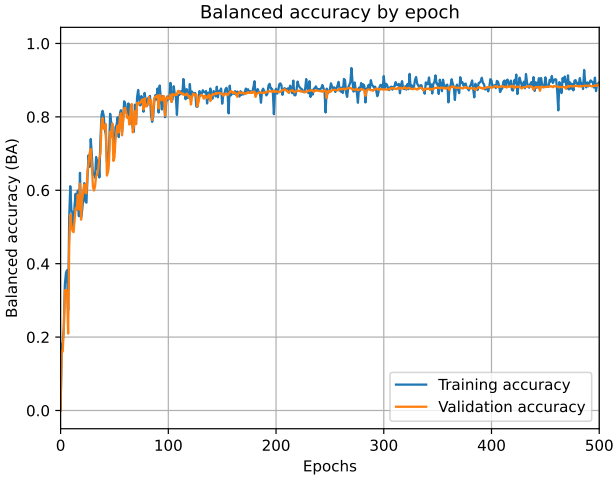

(b) Evolução da acurácia balanceada.

Figura 3: Evolução da entropia cruzada e da acurácia balanceada durante o treinamento para *mini-batch* de 1000 amostras e $\eta = 0,01$.

Com a alteração do tamanho da batelada utilizada, o modelo obteve um decrescimento no seu desempenho, atingindo uma acurácia balanceada de 0,9042. O comportamento da matriz de confusão (Tabela 3) e das métricas de precisão e *recall* (Tabela 4) são similares, porém com menor desempenho comparados ao modelo anterior.

$$BA = 0,9042 \tag{9}$$

	1	**2**	**3**	**4**	**5**	**6**
1	486	0	10	0	0	0
2	28	443	0	0	0	0
3	56	53	311	0	0	0
4	0	3	0	426	61	1
5	0	1	0	54	477	0
6	0	0	0	0	0	537

Tabela 3: Matriz de confusão do classificador com *mini-batch* de 1000 amostras.

Classe	**Precisão**	***Recall***
1	0.9798	0.8526
2	0.9406	0.8860
3	0.7405	0.9688
4	0.8676	0.8875
5	0.8966	0.8866
6	1.0000	0.9981

Tabela 4: Precisão e *Recall* por classe do classificador com *mini-batch* de 1000 amostras por classe.

Mini-batch 2000 amostras

Aumentando ainda mais o número de amostras por *mini-batch*, observa-se uma envolução ainda mais comportada da acurácia balanceada, apresentando oscilações muito menos perceptíveis, como visto na Figura 4b. O decaimento da função de custo, Figura 4a se dá da mesma forma, uma vez que cada evolução do vetor de peso carrega a média da entropia cruzada para cada amostra da batelada.

O desempenho obtido ao utilizar 2000 amostras por *mini-batch* é ainda menor, chegando a uma acurácia balanceada de 0,8898. A matriz de confusão, como pode ser observado na Tabela 5 e precisão e *recall* das classes (Tabela 6), se apresentam da mesma forma, onde mesmo com a queda de *performance*, se observa o mesmo perfil de comportamento para as classes.

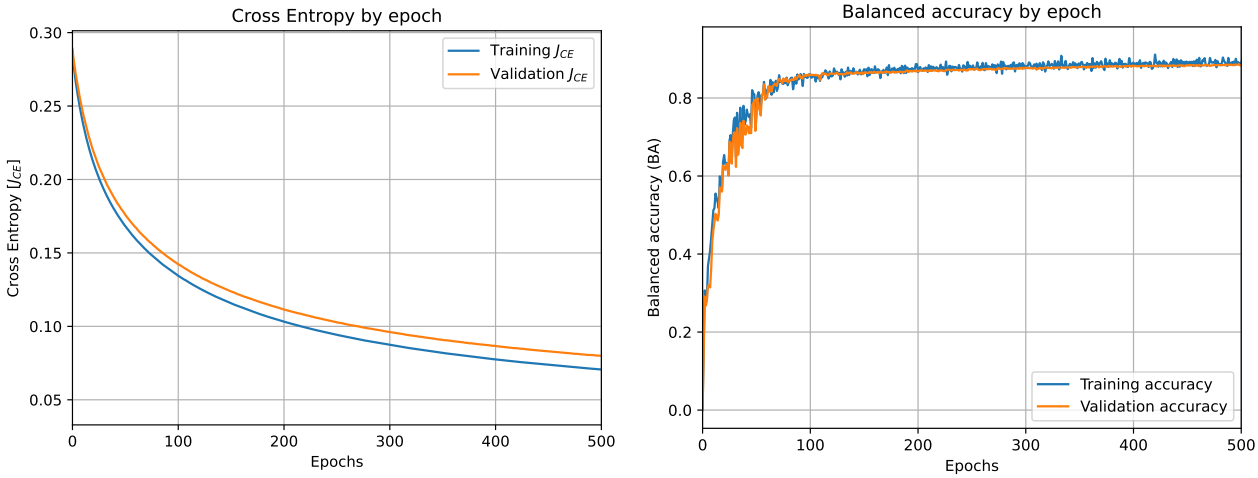

(a) Evolução da entropia cruzada.

(b) Evolução da acurácia balanceada.

Figura 4: Evolução da entropia cruzada e da acurácia balanceada durante o treinamento para *mini-batch* de 2000 amostras e $\eta = 0,01$.

$$BA = 0,8898 \tag{10}$$

	1	**2**	**3**	**4**	**5**	**6**
1	489	0	7	0	0	0
2	27	444	0	0	0	0
3	70	49	301	0	0	0
4	0	3	0	396	91	1
5	1	1	0	58	472	0
6	0	0	0	0	0	537

Tabela 5: Matriz de confusão do classificador com *mini-batch* de 2000 amostras.

Classe	**Precisão**	***Recall***
1	0.9859	0.8330
2	0.9427	0.8934
3	0.7167	0.9773
4	0.8065	0.8722
5	0.8872	0.8384
6	1.0000	0.9981

Tabela 6: Precisão e *Recall* por classe do classificador com *mini-batch* de 2000 amostras .

Análise do número de épocas de treinamento

Foi realizado o treinamento do modelo para a *mini-batch* de 500 amostras em um *range* de 1000 épocas, para observar a acomodação da função de custo. Observa-se na Figura 5a que

a taxa de decrescimento da entropia cruzada vai reduzindo, porém não chega a um estado de regime, também não obtendo o estado de *overfitting* com o aumento do custo para a validação. É possível aferir também que não há grande aumento da acurácia balanceada, se fazendo então, o treinamento de 500 épocas feito anteriormente, suficiente para a obtenção de um modelo que explora de forma suficiente o espaço de hipóteses ($\mathcal{H}$).

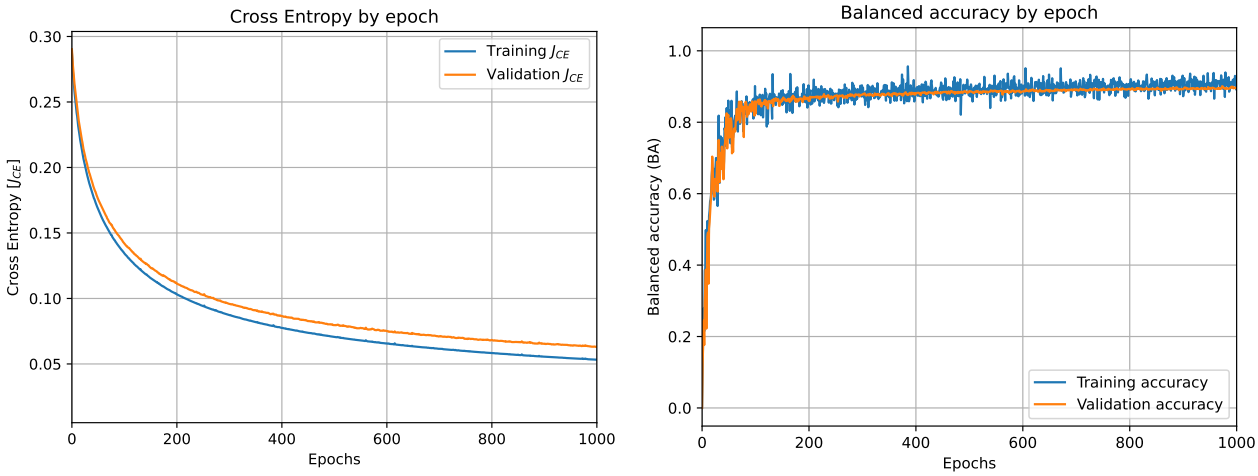

(a) Evolução da entropia cruzada.

(b) Evolução da acurácia balanceada.

Figura 5: Entropia cruzada e acurácia balanceada para o treinamento do modelo com *mini-batch* de 500 amostras por 1000 épocas.

2.2 Dados brutos

Considerando os hiper-parâmetros do melhor classificador utilizando a regressão logística testado com os dados pré-processados coletados do acelerômetro e do giroscópio, treinou-se um classificador para os dados brutos obtidos dos sensores. Esses dados possuem apenas as amostras de dados lidos dos sensores, ou seja, nenhuma informação útil é extraída *a priori*.

A evolução da entropia cruzada e da acurácia balanceada para o treinamento utilizando *mini-batch* de 500 amostras e passo $\eta = 0,01$ é mostrado na Figura 6. Rapidamente se observa a dificuldade em minimizar a função de custo, principalmente para os dados de validação, onde o decaimento da entropia cruzada é muito pequeno. Com a rápida saturação da entropia cruzada de validação, observa-se também a saturação da acurácia balanceada de validação, em um valor abaixo de 0,3, comprovando a dificuldade do modelo em reduzir o erro de classificação.

A acurácia balanceada do classificador após o treinamento é de 0,2506, apresentando um desempenho muito inferior ao classificador anterior treinado com dados tratados. A matriz de confusão da Tabela 7 comprova junto com o cálculo da precisão e *recall* por classe (Tabela 8), que o classificador apresenta uma enorme incapacidade de detectar certas classes, apresentando apenas 8 acertos para a classe 4. É interessante ressaltar que nessa situação, não se vê o mesmo comportamento do desempenho de classes visto anteriormente, onde a classe 3 que antes apresentava a pior precisão, agora apresenta a maior, pois com a mudança dos atributos, o modelo tenta aprender novas formas de relacionar os dados.

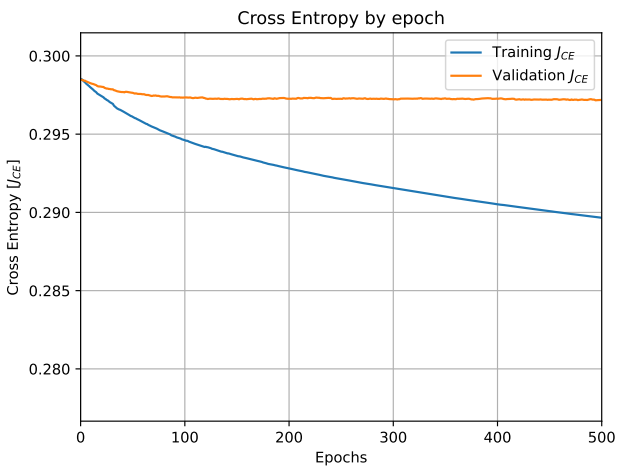

(a) Evolução da entropia cruzada.

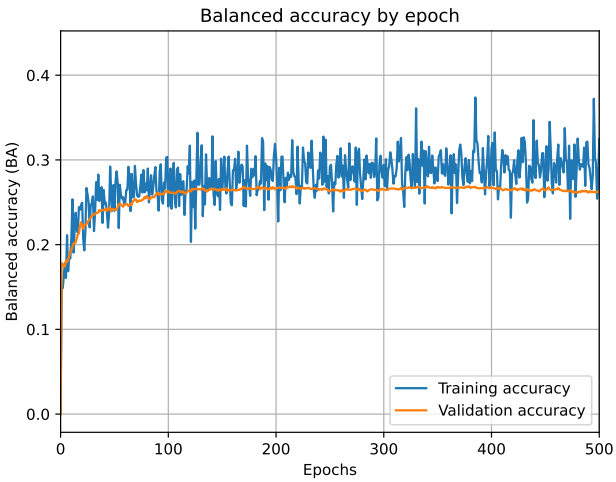

(b) Evolução da acurácia balanceada.

Figura 6: Entropia cruzada e acurácia balanceada para o treinamento do modelo com *mini-batch* de 500 amostras por 500 épocas com dados brutos.

$$BA = 0,2506 \tag{11}$$

	1	**2**	**3**	**4**	**5**	**6**
1	99	177	149	13	19	39
2	43	184	173	5	14	52
3	17	127	228	16	12	20
4	15	109	139	8	31	189
5	31	163	165	9	34	130
6	19	161	158	5	38	156

Tabela 7: Matriz de confusão do classificador com *mini-batch* de 500 amostras com dados brutos.

Classe	**Precisão**	***Recall***
1	0.1996	0.4420
2	0.3907	0.1998
3	0.5429	0.2253
4	0.0163	0.1429
5	0.0639	0.2297
6	0.2905	0.2662

Tabela 8: Precisão e *Recall* por classe do classificador com *mini-batch* de 500 amostras com dados brutos.

3 Classificação via *k neareast neighbours*

A classificação pelo método *k neareast neighbours* é baseada em inferir a classe do dado a ser classificado com base nos k dados mais próximos à ele. Como hiper-parâmetros para esse problema, têm-se principalmente o valor de k, a ordem p da distância de Minkowski entre os dados e o critério de classificação.

O critério de classificação pode se basear puramente na classe majoritária entre os k vizinhos, ou levar em consideração a distância como um peso, que normalmente é inversamente proporcional a distância, evidenciando o rótulo dos pontos mais próximos do dado teste.

3.1 Dados tratados

Para implementação do algoritmo de k-NN, foi escolhido a utilização da distância euclidiana no espaço dos atributos, e a decisão do rótulo vencedor por meio do voto majoritário dos k vizinhos mais próximos.

Para obtenção do valor de k, foi executada uma busca em *grid* do hiper-parâmetro, variando seu valor entre 1 e 29. Utilizando da técnica de validação cruzada *k-fold*, com quatro pastas, foi realizada a inferência das classes dos dados da pasta de validação com base nos vizinhos mais próximos encontrados nas pastas de treinamento, para cada valor de k testado. A Figura 7 exibe à evolução da acurácia balanceada para os valores de k, obtendo um conjunto de valores ótimos em (12).

$$k = [17\ 28\ 12\ 18] \tag{12}$$

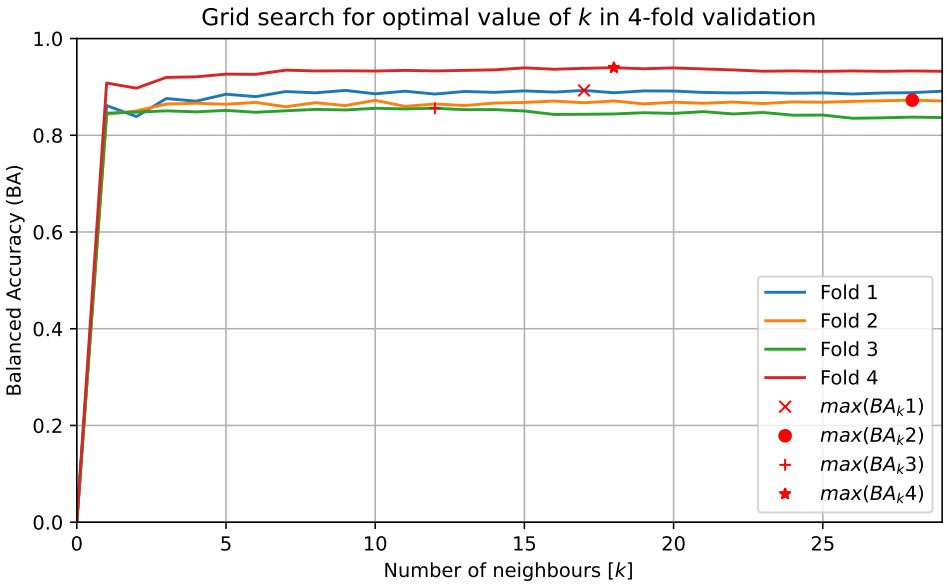

Figura 7: Busca em *grid* do valor de k ótimo utilizando *4-fold validation*.

A heurística escolhida para avaliar o melhor valor de k com base no conjunto obtido por meio da busca em *grid* com validação cruzada se dá em obter a acurácia balanceada média das

pastas e obter o número de vizinhos que maximiza essa combinação das pastas. A Figura 8 mostra a progressão da acurácia balanceada média de acordo com k, e assim se obtém o valor de k ótimo em $k = 15$.

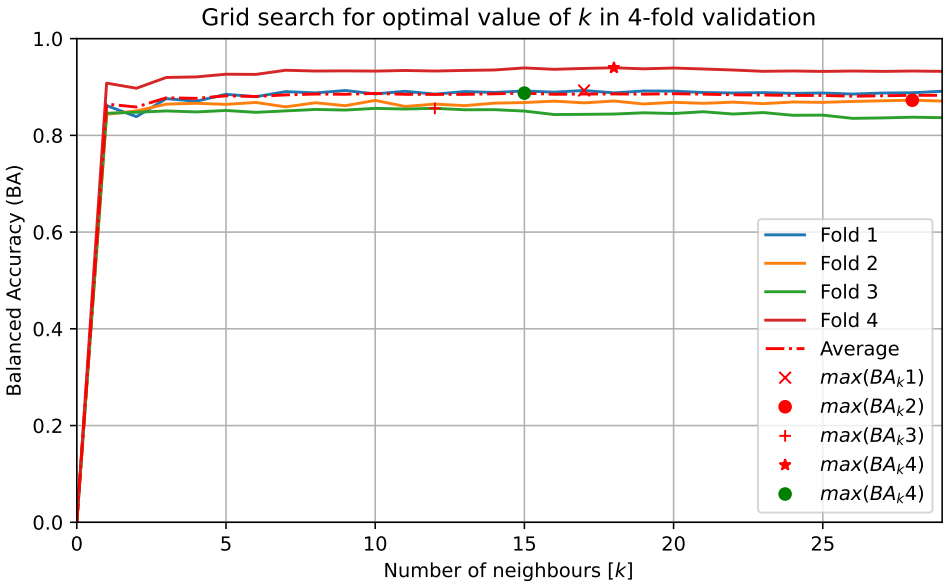

Figura 8: Busca em *grid* do valor de k ótimo utilizando *4-fold validation*.

Uma vez definido o classificador ótimo, obtém-se os indicadores de performance do classificador com base nos dados de teste. A acurácia balanceada encontrada foi de 0,8991 e a matriz de confusão do classificador por ser vista na Tabela 9.

$$BA = 0,8991 \tag{13}$$

	1	**2**	**3**	**4**	**5**	**6**
1	488	0	8	0	0	0
2	39	427	5	0	0	0
3	51	44	325	0	0	0
4	0	4	0	389	98	0
5	0	0	0	31	501	0
6	0	0	0	1	1	535

Tabela 9: Matriz de confusão do classificador k-NN com $k = 15$.

Extraindo da matriz de confusão as métricas de precisão e *recall*, obtém-se a Tabela 10. Pode-se observar que a classe 3 foi a que apresentou menor precisão, sendo muito confundida com a classe 1 e 2. Já a classe 1 possuí o pior *recall*, uma vez que as classes 2 e 3 se confundem com a 1. A classe 6 foi a que apresentou o melhor desempenho, apresentando *recall* unitário, logo, nenhuma classe se confunde com ela, e a maior precisão, muito próxima de 1.

Classe	Precisão	*Recall*
1	0.9839	0.8443
2	0.9066	0.8989
3	0.7738	0.9615
4	0.7923	0.9240
5	0.9417	0.8350
6	0.9963	1.0000

Tabela 10: Precisão e *Recall* por classe do classificador.

Comparação com a regressão logística

Ao comparar os classificadores utilizando a regressão logística e o k-NN, observa-se que a acurácia balanceada para a regressão logística de melhor desempenho foi superior, mas para ter uma comparação mais minuciosa entre os dois classificadores, deve-se analisar também suas matrizes de confusão. Comparando a precisão e o *recall*, o desempenho das classes em *ranking* se apresenta da mesma forma, porém, para a regressão logística a classe 6 conseguiu obter tanto precisão quanto *recall* máximo.

A regressão logística apresentou um desempenho relativo 1,87% maior que o k-NN para a acurácia balanceada, porém possuí uma complexidade muito maior. Para obter o modelo de regressão logística multi-classe com *softmax*, é necessário realizar o treinamento do modelo, buscando variar os hiper-parâmetros para se conseguir o melhor desempenho. Essa etapa demanda de muito processamento, porém garante uma utilização do classificador mais leve, uma vez que é necessária apenas o vetor de pesos. Já o k-NN, não demanda treinamento, sendo necessária apenas a inferência da classe com base nos vizinhos mais próximos, o que apesar de consumir armazenamento para manter o *dataset*, não precisa de tanto processamento prévio, sendo uma solução simples e de rápida implementação.

Porém, devido a busca em *grid* utilizando a validação *k-fold* para obter o melhor k para os dados de treinamento, tal etapa demandou bastante processamento, o que elevou consideravelmente a complexidade do k-NN. Em relação ao tempo para realizar a classificação, o k-NN também apresentou um tempo maior em comparação à regressão logística, devido à necessidade de varrer todo o *dataset* para obter os dados mais próximos. Por outro lado, para a solução iterativa, basta aplicar a função *softmax* com os pesos obtidos no treinamento, o que apresenta um tempo de execução consideravelmente menor.

Comparação com o k ótimo

Somente a título de comparação, foi realizada a busca em *grid* do melhor valor de k, utilizando os próprios dados de teste do problema. A Figura 9 mostra a evolução da acurácia balanceada dos dados de teste para o aumento do número de vizinhos, chegando ao valor ótimo em $k = 8$, com $BA = 0,9028$.

Em comparação com o número de vizinhos obtidos via validação em k-pastas, observa-se

que o número de vizinhos é perto da metade do obtido anteriormente, e apresentando uma performance melhor. Porém, ao se realizar uma busca de um hiper-parâmetro com métodos de busca em *grid* utilizando validação cruzada, busca-se obter o melhor valor com base nos dados de treinamento, que são os únicos conhecidos na etapa de treinamento/modelagem do classificador. Espera-se que os dados de treinamento sejam suficiente para generalizar os dados como um todo, fazendo com que a solução ótima para o *dataset* de treinamento tenda a ser a solução ótima para todos os dados inéditos que o modelo irá receber.

Dessa forma, mesmo o valor de k tendo mudado consideravelmente, a acurácia não apresentou grandes mudanças, sendo ainda sim um bom modelo para conseguir fazer a classificação dos dados de teste.

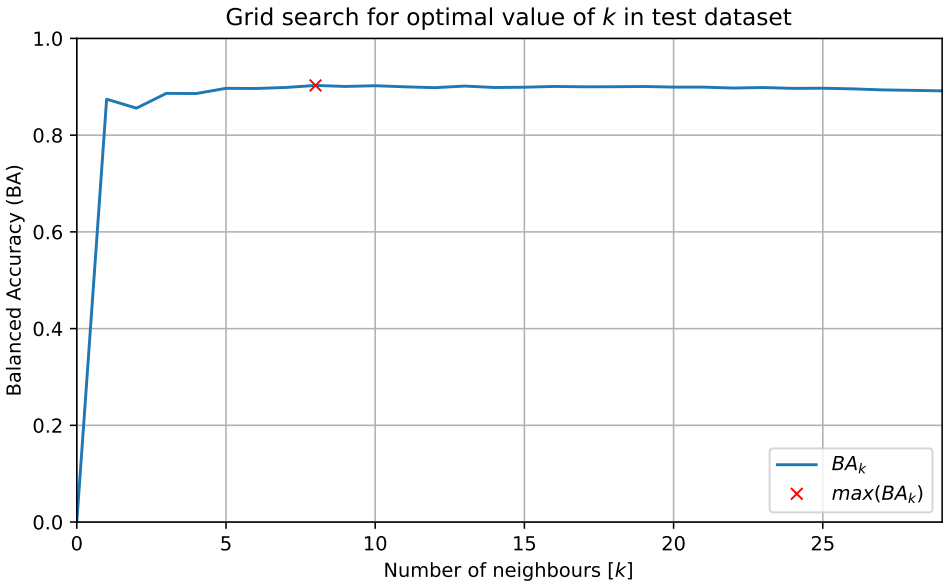

Figura 9: Busca em *grid* do valor de k ótimo para o conjunto de testes.

3.2 Dados brutos

Utilizando agora para a aplicação do k-NN o conjunto de dados brutos, formados pelos 768 atributos obtidos diretamente dos sensores para cada janela de tempo, utilizando as mesmas considerações realizadas anteriormente, realiza-se novamente a busca em *grid* utilizando validação cruzada por meio da técnica *k-fold* com 4 pastas. A Figura 10 exibe a acurácia balanceada do classificador para o grupo de validação com cada uma das pastas de acordo com o aumento do número de vizinhos, onde foram obtidos os valores de k ótimos para cada pasta de acordo com (14).

$$k = [2\ 2\ 2\ 1] \tag{14}$$

Adotando novamente a heurística de obter a acurácia balanceada média para todas as pastas, a Figura 10 apresenta a curva dessa grandeza calculada na curva ponto-tracejada, e obtém-se que a métrica é maximizada por $k = 2$.

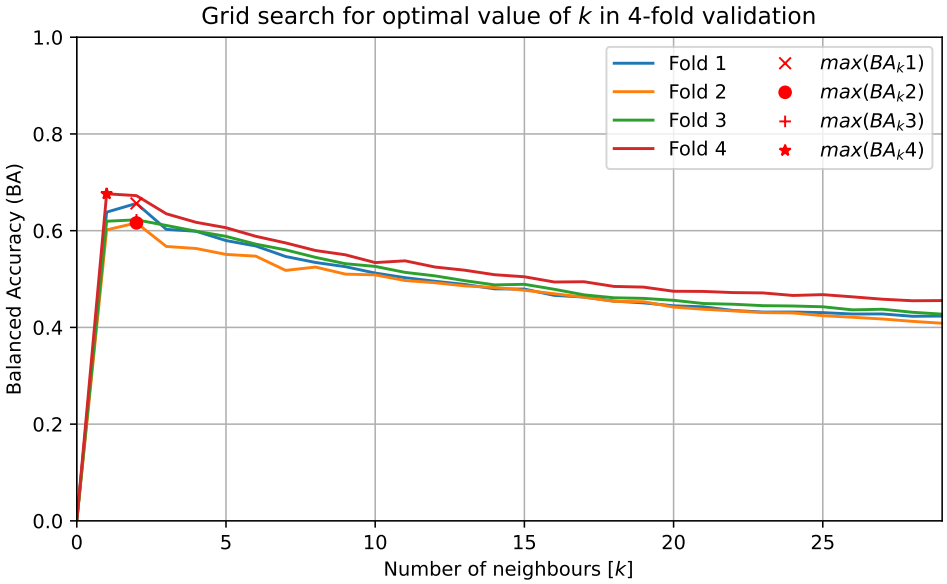

Figura 10: Busca em *grid* do valor de k ótimo utilizando *4-fold validation*.

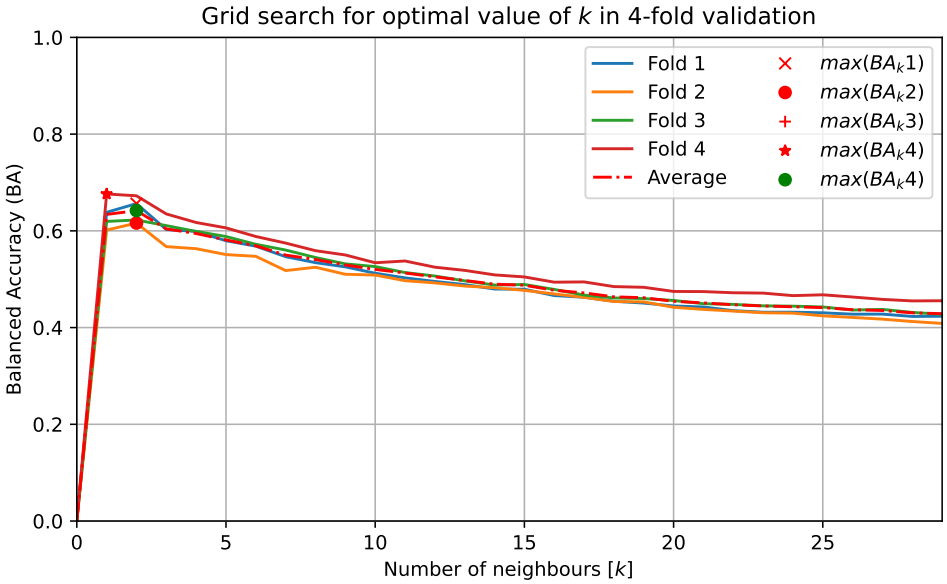

Figura 11: Busca em *grid* do valor de k ótimo utilizando *4-fold validation*.

Realizando o teste do classificador obtido para o conjunto de dados brutos de teste, foi obtida uma acurácia balanceada que 0,6233, sendo sua matrix de confusão apresentada na Tabela 11 e os valores de precisão e *recall* na Tabela 12. Observa-se que a acurácia balanceada para dados brutos foi bem menor que utilizando o mesmo método para dados tratados, uma vez que existem menos informações extraídas para gerar vizinhos com informações de fácil comparação, tal resultado é esperado. Porém, o método de vizinhos mais próximos apresentou um resultado muito superior que a regressão logística para os dados brutos dos sensores, com mais que o dobro de acurácia.

$$BA = 0.6233 \tag{15}$$

Observando a matrix de confusão (Tabela 11), é possível perceber que as classes 4, 5 e 6 não são confundidas com as classes 1, 2 e 3, porém são muito confundidas entre sí. Como essas classes representam o comportamento de estar de pé, sentado e deitado, espera-se que não haja movimento, ou seja, as leituras dos sensores para cada janela tendem a variar pouco, fazendo com que seja fácil diferenciar as classes que demandam movimento (caminhar, subir e descer escadas). Já as classes de movimento, essas se confundem com as classes que não possuem movimento, principalmente com a classe 5, que representa o estado de pé.

	1	**2**	**3**	**4**	**5**	**6**
1	355	6	1	25	98	11
2	7	343	0	35	71	15
3	11	17	121	69	135	67
4	0	0	0	441	16	34
5	0	0	0	176	311	45
6	0	0	0	217	38	282

Tabela 11: Matriz de confusão do classificador k-NN com $k = 2$ para dados brutos.

Ao fornecer dados brutos para o classificador, o mesmo aprende como realizar a classificação por meio de características diferentes dos dados, ao se comparar com os dados tratados. Dessa forma, ao mudar os atributos e como eles são considerados, se observa que o comportamento do desempenho das classes muda consideravelmente, onde a classe 4, que para dados tratados apresentada a segunda pior precisão, agora apresenta a melhor. Já a classe 3, passou a apresentar o melhor *recall*.

Classe	**Precisão**	***Recall***
1	0.7157	0.9517
2	0.7282	0.9372
3	0.2881	0.9918
4	0.8982	0.4579
5	0.5846	0.4649
6	0.5251	0.6211

Tabela 12: Precisão e *Recall* por classe do classificador para dados brutos.

4 Análise dos resultados

Com base nos ensaios realizados, foi possível obter classificadores por meio das técnicas regressão logística e k vizinhos mais próximos, para dados pré-processados e dados brutos. Por meio dos gráficos de treinamento/desempenho, observou-se o comportamento das métricas entropia cruzada e acurácia balanceada durante o treinamento/otimização dos hiper-parâmetros. Além disso, através das matrizes de confusão, onde foi possível observar melhor o comportamento do classificador e o desempenho das classes.

A escolha de hiper-parâmetros se mostrou importante para o desempenho do classificador. Para a regressão logística, observa-se que o tamanho do *mini-batch* influencia no desempenho final da acurácia balanceada, enquanto o tamanho do passo interfere diretamente na convergência do treinamento. A busca por um valor ótimo pode ser exaustiva, se feita por busca em *grid*, porém foi possível obter bons resultados ao aproximar os valores com poucos testes feitos de forma prévia ao treinamento. Ao apresentar dados brutos para a regressão logística, é notável a dificuldade que o modelo teve de minimizar a função de custo e evoluir com a capacidade de classificação, uma vez que os dados possuem menos informações explícitas para serem aproveitadas.

Já para o k-NN, como há somente um hiper-parâmetro a ser encontrado, foi possível a realização da busca em *grid*, utilizando um método de validação mais sofisticado, o *k-fold*. Com a otimização do número de vizinhos, obteve-se o valor ótimo para cada uma das pastas, sendo feita a maximização da métrica médias de todas as pastas para encontrar um único valor k. Como a validação cruzada para encontrar tal valor é feita para os dados de treinamento, não se sabe se esse valor é ótimo para os dados de treinamento, como realmente não foram, como mostrado anteriormente. Enquanto para dados tratados, o valor encontrado de k foi 15, o valor ótimo se posicionou em 8, mas como a acurácia balanceada se manteve consideravelmente estável para todos os valores maiores que 8, o desempenho do classificador se manteve aceitável. Um fato importante de ser ressaltado, é que para os dados tratados, o k-NN apresentou um desempenho ligeiramente menor que a regressão logística, porém já para os dados brutos, sua acurácia balanceada foi mais de duas vezes maior, mostrando que teve maior capacidade de correlacionar os dados com base na vizinhança de dados rotulados.

Como foi visto nas matrizes de confusão, e nas tabelas de precisão e *recall* por classe, as classes não possuem desempenho similar, porém esses desempenhos vem a apresentar padrões. As atividades classificadas podem se dividir em grupos, seja pela movimentação: Atividades em movimento e atividades em repouso, e ainda pode-se pensar na posição: Atividades com o tronco ereto, atividades com o tronco inclinado e atividades com o tronco na horizontal. Observa-se que as classes de repouso dificilmente são confundidas pelas classes de movimento, e também que a classe deitado, por ser a única com o tronco na posição horizontal, apresenta maior distinção das outras.

Ao realizar a classificação com dados pré-processados, as classes se tornam mais distintas por meio da extração de informações que não estão presentes diretamente nos dados, como componentes de frequência, componentes estatísticas e informações filtradas dos dados originais.

Ao se basear nessas novas informações, se torna mais fácil diferenciar as atividades, principalmente ao se considerar atividades que se alteram por componentes de frequência e amplitude. Ao concatenar os dados dos sensores, se obtém um *dataset* com 768 atributos, em frente aos 561 do conjunto de dados tratados. Porém, os dados tratados trazem inúmeras informações, enquanto os dados brutos fornecem apenas 6 sequências de leituras de aceleração e orientação.

A queda de desempenho ao treinar os mesmos classificadores com os dados brutos, das mesmas atividades, mostra que os modelos de aprendizado utilizados não possuem capacidade suficiente de extrair informações contidas dentro dos dados de entrada, devido a sua baixa complexidade e pouca ou nenhuma mudança de configuração dos dados. Os modelos baseados em *deep learning*, por exemplo, apresentam profundidade suficiente para poderem receber dados de entrada com pouco ou nenhum pré-processamento, e a partir de inúmeras camadas não lineares, transformar o problema inicial em um novo problema a cada camada, onde cada uma delas se especializa em obter determinados padrões dos dados, fazendo com que a extração de informações internas aos dados sejam realizadas pelo modelo.

Anexos

Códigos fonte

Todos os códigos fonte e arquivos de dados utilizados para a elaboração deste documento podem ser encontrados no repositório do GitHub no link: github.com/toffanetto/ia048.